

**МИНОБРНАУКИ РОССИИ**  
**САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ**  
**ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ**  
**«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)**  
**Кафедра МОЭВМ**

**ОТЧЕТ**  
**по научно-исследовательской работе**  
**Тема: Разработка программы оценки ситуации в**  
**мультиагентной среде**

Студент гр. 7304

Петруненко Д.А.

Руководитель

Беляев С.А.

Санкт-Петербург

2022

**ЗАДАНИЕ**  
**НА НАУЧНО ИССЛЕДОВАТЕЛЬСКУЮ РАБОТУ**

Студент Петруненко Д.А.

Группа 7304

Тема НИР: Разработка программы оценки ситуации в мультиагентной среде

Задание на НИР:

Разработка программы определения стратегии команды противника в среде виртуального футбола

Сроки выполнения НИР: 01.09.2022 – 23.12.2022

Дата сдачи отчёта: 23.12.2022

Дата защиты отчёта: 27.12.2022

Студент	_____	Петруненко Д.А.
---------	-------	-----------------

Руководитель	_____	Беляев С.А.
--------------	-------	-------------

## **АННОТАЦИЯ**

В данной работе рассмотрена актуальность проблемы прогнозирования и определения тактики команды противника в среде виртуального футбола. На основании результатов анализа аналогов, разработанной математической модели, архитектура программы был разработан и протестирован прототип модели нейронной сети для определения тактики команды противника на каждом такте игры с учётом как видимых игроков, так и недавно исчезнувших из поля зрения. Выполнено дообработка и доразметка данных о нескольких сыгранных матчах. Далее с использованием полученных данных выполнена корректировка полученного прототипа. Описан план работ на весенний семестр.

## **SUMMARY**

In this paper, the relevance of the problem of forecasting and determining the tactics of the opposing team in the virtual football environment is considered. Based on the results of the analysis of analogs, the developed mathematical model, the architecture of the program, a prototype of a neural network model was developed and tested to determine the tactics of the opposing team at each stroke of the game, taking into account both visible players and recently disappeared from view. Data on several matches played has been further processed and marked up. Then, using the obtained data, the correction of the obtained prototype was performed. The work plan for the spring semester is described.

## СОДЕРЖАНИЕ

Введение.....	5
1. ПОСТАНОВКА ЗАДАЧИ.....	7
2. РЕЗУЛЬТАТЫ РАБОТЫ В ОСЕННЕМ СЕМЕСТРЕ.....	9
2.1. Планирование на осенний семестр .....	9
2.2. Расширение набора данных.....	9
2.3. Доработка модуля определения стратегии противника на текущем такте работы.....	11
2.3.1. Определения стратегии противников для видимых игроков на текущем такте игры .....	11
2.3.2. Определения стратегии противников на текущем такте игры с использованием данных о недавно исчезнувших из поля зрения игроков..	16
2.4. Корректировка точности получаемых результатов .....	18
3. ПЛАН РАБОТЫ НА ВЕСЕННИЙ СЕМЕСТР.....	19
Заключение .....	20
Список использованных источников .....	21

## ВВЕДЕНИЕ

Для изучения искусственного интеллекта на данный момент уже существует достаточно большое количество платформ, различным по своим задачам. Для научных исследований в области искусственного интеллекта существуют, например, Gym OpenAI, GVGAI. Для проведения соревнований, например, RoboCup 2D Soccer Simulation League Champion [1], RoboCup Rescue Simulation [2]. Соревновательная среда виртуального футбола Soccer Simulation [3] позволяет приблизить моделирование к реальному миру. Так как среда обладает высокой динамичностью, информационной шумностью, неполнотой, проблемами принятия решений и множеством агентов. Поэтому данная среда используется для различных исследований многоагентных систем.

Среда виртуального футбола подразумевает постоянное противодействие команде противника во время игры. При этом для данного противодействия и достижения основной цели – выиграть игру, забив больше мячей, чем противник, используются различные стратегии. При этом применение той или иной стратегии выполняется на основании текущего состояния мира. При выборе подходящей стратегии выполняется прогнозирование вероятных действий противника и его местоположения. Также выбор должен зависеть и от текущей стратегии противников. Стратегия противников может определяться на основании оценки действий противников на протяжении ряда игр[4], оценке действий на текущем такте игры[5], агентом-тренером, который оценивает положения всех игроков на поле, а затем сообщает о сделанных выводах игровым агентам [6, 7], оценке местоположений других агентов текущим игроком [8, 9,10]. Учёт предыдущих тактов игры и прогнозирование будущих местоположений и действий противника позволяют обогатить модель текущего состояния мира, на основе чего сделать более точное определение стратегии противника и выбор собственной стратегии.

К действиям противника можно отнести удары по воротам, передачи, перехват мяча и ведение мяча. Такие действия, как движения на перехват и ведение мяча возможно распознать определением местоположений агента и мяча за определённый промежуток времени. Причём этот промежуток времени ограничивается небольшим значением тактов, так как среда виртуального футбола очень динамична. Определение местоположения объектов на поле возможно различными методами: методы, использующие только текущее местоположении агентов и статические объекты поля (такие как флаги, линии, ворота), навигация по ближайшему флагу и дальней линии и навигация по двум ближайшим флагам и дальней линии [11], методы, использующие, кроме текущего состояния мира, также и предыдущие для корректировки определения местоположения, навигация с использованием фильтра Калмана [11-13], методы, использующие вероятностные предположения, а затем выполняющие уточнения этих предположений, навигация с использованием фильтра частиц[11, 12] и Метод RFS (случайных конечных множеств)[14]. При этом все перечисленные методы используют данные только о видимых объектах. Попытка обогатить модель текущего такта игры учётом агентов, которые недавно исчезли из поля зрения, представлена в статье [16].

Также выделяется и то, что текущему агенту неизвестны и собственные координаты, которые необходимо вычислять основываясь на статических объектах поля (используются те же объекты, что и в методах использующие только текущее местоположении агентов).

## 1. ПОСТАНОВКА ЗАДАЧИ

В многоагентных средах от оценки ситуации и выполняемое на её основе планирование действий является наиболее важной проблемой создания интеллектуальных агентов. В частности, в одной из многоагентных сред Soccer Simulation [3] планирование осуществляется на основе данных, поступающих от сенсоров агентов. При этом оценка ситуации может быть дополнена и данным прогнозирования, выполненного для агентов, недавно исчезнувших из поля зрения. От правильной оценки ситуации и текущей тактики противников зависит исход игры, так как на основе планирования выполняется выбор тактики действий в игре. Существующие решения используют для выполнения оценки информацию о видимых объектах, прогнозирования будущих действий противника, но при этом поведение невидимых объектов для них неизвестно. Учёт их поведения дополнит модель представления о мире и улучшит точность прогноза развития ситуации на поле. За счёт получения более точной модели представления о мире возможно более точно определять текущую тактику противника. Поэтому решением данной проблемы является создание программы, которая способна на основе данных, поступающих как от сенсоров, так и полученных в результате прогнозирования координат как для видимых игроков, так и для недавно исчезнувших из поля зрения игроков, определять тактику игры оппонентов в настоящий момент времени, а также понять, какие действия противник может предпринять в последующих тактах игры.

Цель: Разработка программы, которая способна на основе данных, поступающих как от сенсоров, так и полученных в результате прогнозирования координат для игроков недавно исчезнувших из поля зрения, определять тактику игры оппонентов в настоящий момент времени.

Для решения поставленной проблемы необходимо решить следующие задачи:

- Выбор метода определения текущей тактики противника.

- Разработка математической модели для выполнения прогнозирования и определения текущей тактики противника как для видимых, так и для невидимых агентов.
- Разработка архитектуры построенной на основании созданной математической модели.
- Создание программы, основанной на разработанной математической модели и архитектуры.
- Корректировка получаемых результатов – уменьшение погрешности прогнозирования действий, увеличение точности классификации стратегии.
- Прогнозирование дальнейших действий противника в зависимости от текущей стратегии

В рамках данного отчёта будет рассматриваться разработанный прототип модели нейронной сети для определения текущей тактики противников.



## 2. РЕЗУЛЬТАТЫ РАБОТЫ В ОСЕННЕМ СЕМЕСТРЕ

### 2.1. Планирование на осенний семестр

Первоначальный план работы на осенний семестр представлен в табл. 1.

Таблица 1 – Первоначальный план работы на осенний семестр.

Период	Задача
10.06. – 01.08. 2022	Обработка большего числа игр и расширение базы размеченных данных для видимых игроков
01.08. – 01.11. 2022	Обработка и разметка данных для недавно исчезнувших игроков из поля зрения
01.11. – 15.11. 2022	Доработка модуля определения стратегии для видимых игроков на текущем такте работы
15.11. – 01.12. 2022	Доработка модуля определения стратегии с учётом недавно исчезнувших из поля зрения игроков на текущем такте работы
01.12. – 31.12. 2022	Корректировка точности получаемых результатов

На основании результатов анализа аналогов[18], математической модели, архитектуру будущего решения, а также собранного набора данных и построенного первого прототипа выполнялись дальнейшие исследования, в частности сбор большего числа данных для обучающего набора, доработка модуля определения стратегий и корректировка его точности.

### 2.2. Расширение набора данных

Данные для экспериментов взяты в [19]. Результатом обработки и разметки данных стало пополнение изначального набора данных до 3000 записей, содержащими 4 вида стратегий противника. Две атакующие, в частности, атака центра поля и атака вблизи ворот, и две защитные тактики, защита центра поля и защита ворот. Каждая запись в наборе данных для видимых игроков состоит из двух векторов противников и союзников,

размерность которых зависит от количества квадратов на которые разбито поле, содержащих количество видимых текущим игроком объектов. Также данные содержат вычисленные текущим игроком собственное местоположение и сторону, за которую играет. В дальнейшем вектора были дополнены игроками, которые недавно исчезли из поля зрения.

Для разметки строился схематичное представление поля текущего состояния для динамических объектов. Схематичное представление поля представлено на рисунке 1.




Рисунок 1. Схематичное представление поля для одного такта игры

Для дополнения данных разметки строилось также схематичное представление поля текущего состояния как для динамических видимых объектов, так и для недавно исчезнувших объектов. Схематичное представление поля представлено на рисунке 2.




Рисунок 2. Схематичное представление поля для одного такта игры, с учётом недавно исчезнувших из поля зрения игроков

## 2.3. Доработка модуля определения стратегии противника на текущем такте работы

### 2.3.1. Определения стратегии противников для видимых игроков на текущем такте игры

Для выполнения определения стратегии противников изначально выполняется процедура определения местоположения динамических объектов на поле. После получения местоположения поле разбивается на квадратные области, количество областей может варьироваться. Затем объекты начинают разделяться по областям, в которых они находятся. На выходе получают два вектора распределения, размерность равна количеству квадратных областей, значения в векторах равно количеству объектов в данной квадратной области. В одном из векторов хранятся распределения игроков союзной команды, во втором распределение противников. Эти данные затем подаются на вход нейронной сети для определения стратегии.

Исходный код программы разрабатываемой программы размещён по ссылке [20]. Прототипом послужила конфигурация нейронной сети выбранного метода Opponent Formation Identification Based on Position Information [6].

В общем случае модель представляет собой входной слой, количество нейронов равно размерности одного входного элемента. Затем идут один или более скрытых векторов с различным количеством нейронов. Количество нейронов выходного слоя равно количеству стратегий во входных данных. Все слои являются полносвязными. Количество нейронов входного слоя для текущих данных равно 49, так как поле разбивается на 24 квадрата (размерность 6x4). А также кроме двух векторов подаётся и сторона ворот, за которую играет текущий игрок. Для уменьшения возможности переобучения модели используется компонент dropout, который позволяет отключать некоторые случайно выбранные нейроны при каждой из итераций.

В ходе исследования рассматривались конфигурации сетей с различным количеством скрытых слоёв. Архитектуры сетей представлены в таблицах 2, 3, 4.

Таблица 2. Архитектура первого прототипа нейронной сети

Слой	Параметры	Активация
Dense	units= number of grid	relu
Dropout	0.2	-
Dense	units= number of grid / 2	relu
Dense	units= number class	softmax

Таблица 3. Архитектура второго прототипа нейронной сети

Слой	Параметры	Активация
Dense	units= number of grid	relu
Dropout	0.2	-
Dense	units= number of grid / 2	relu
Dropout	0.1	-
Dense	units= number of grid / 3	relu
Dense	units= number class	softmax

Таблица 4. Архитектура третьего прототипа нейронной сети

Слой	Параметры	Активация
Dense	units= number of grid	relu
Dropout	0.2	-
Dense	units= number of grid * 2	relu
Dense	units= number class	softmax

Результаты обучения сети показаны на рисунках 3, 4, 5.




Рисунок 3. Результаты обучения первого прототипа модели нейронной сети для определения стратегий противника с использованием только видимых игроков на данном такте игры




Рисунок 4. Результаты обучения второго прототипа модели нейронной сети для определения стратегий противника с использованием только видимых игроков на данном такте игры




Рисунок 5. Результаты обучения третьего прототипа модели нейронной сети для определения стратегий противника с использованием только видимых игроков на данном такте игры

Исследования проводились на разном количестве эпох, от 100 до 1500. Для данные моделей на текущих данных количество эпох равно 500 выдавало наиболее наглядную картину обучения, где можно заметить, как значение точности перестаёт расти, а значение потерь начинает увеличиваться или стагнировать на одном уровне.

Для тестирования точности моделей был выделен отдельный набор данных, который не использовался в обучении. Размер тестового набора данных равен 500 записям.

Точность обучения моделей варьируется от 85-90%. На тестовом наборе данных точность определения варьируется 75-81%. Наиболее хорошо показал себя второй прототип с точностью 87-90% на обучающем наборе данных и 78-81% на тестовом наборе данных. Наихудший результат показал третий прототип, который является прототипом широкой нейронной сети с точностью 85-89% на обучающем наборе данных и 75-77% на тестовом наборе данных.

### 2.3.2. Определения стратегии противников на текущем такте игры с использованием данных о недавно исчезнувших из поля зрения игроков

Дополненный набор данных, включающий недавно исчезнувших из поля зрения игроков, используется для исследования влияния на точность определения стратегии противников. Представленные в таблицах 2, 3, 4 были обучены с использованием данного набора данных. Количество эпох обучения равно 500. Результаты обучения представлены на рисунках 6, 7, 8.




Рисунок 6. Результаты обучения первого прототипа модели нейронной сети для определения стратегий противника с использованием данных о недавно исчезнувших из поля зрения игроков






Рисунок 7. Результаты обучения второго прототипа модели нейронной сети для определения стратегий противника с использованием данных о недавно исчезнувших из поля зрения игроков




Рисунок 8. Результаты обучения третьего прототипа модели нейронной сети для определения стратегий противника с использованием данных о недавно исчезнувших из поля зрения игроков

Точность обучения моделей варьируется от 87-92%. На тестовом наборе данных точность определения варьируется 70-84%. Наиболее хорошо также показал себя второй прототип с точностью 88-90% на обучающем наборе данных и 82-84% на тестовом наборе данных. Наихудший результат показал третий прототип, который является прототипом широкой нейронной

сети с точностью 88-92% на обучающем наборе данных и 79-82% на тестовом наборе данных.

## **2.4.   Корректировка точности получаемых результатов**

Корректировка точности проводилась варьированием количества эпох обучения, размеров пакета записей для одной итерации, диапазон варьировался от 100 до 4000. Для данных моделей наилучшие результаты были получены с размером пакета (batch) равное 2000. Для уменьшения переобучения был использован элемент модели dropout, который выключал от 10 до 40% нейронов за итерацию. Наилучшая конфигурация, полученная для данных прототипов, представлена в таблицах 2, 3, 4.

### 3. ПЛАН РАБОТЫ НА ВЕСЕННИЙ СЕМЕСТР

План работы на весенний семестр представлен в таблице 5.

Таблица 5 – План работы на весенний семестр.

<b>Период</b>	<b>Задача</b>
01.01. – 01.03 2023	Корректировка точности моделей с использованием более мелкой сетки разбиения поля в наборе данных
01.03. – 15.04 2023	Разработка модуля прогнозирования действий противника в зависимости от текущей стратегии противника
15.04. – 31.05 2023	Тестирование полученной программы на реальных играх

## **ЗАКЛЮЧЕНИЕ**

В ходе работы за осенний семестр выполнена доработка набора данных как с использованием только видимых игроков так и дополнение данного набора данными о недавно исчезнувших из поля зрения. Произведена доработка модулей определения стратегий, заключающаяся в обучении и исследовании прототипов моделей нейронных сетей полученных в ходе обзора аналогов, построения математической модели и архитектуры будущей программы.

Результаты, полученные в ходе исследования, показывают, что широкие нейронные сети менее точны в предсказании текущей стратегии противника, в то время как глубокие нейронные сети более точно определяют текущую стратегию. Выполнена первичная корректировка точности определения стратегии.

В весеннем семестре предполагается проверка влияния размерности входного вектора, который равен количеству квадратов на которое делится поле, на точность определения стратегии противника. Затем на основании полученных результатов разработка модуля прогнозирования действий противника в зависимости от текущей стратегии, после чего планируется тестирование полученной программы на реальных играх.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Suzuki Y., Fukushima T., Thibout L., Nakashima T., Akiyama H. (2019) Game-Watching Should be More Entertaining: Real-Time Application of Field-Situation Prediction to a Soccer Monitor. In: Chalup S., Niemueller T., Suthakorn J., Williams MA. (eds) RoboCup 2019: Robot World Cup XXIII. RoboCup 2019. Lecture Notes in Computer Science, vol 11531. Springer, Cham. [https://doi.org/10.1007/978-3-030-35699-6\\_35](https://doi.org/10.1007/978-3-030-35699-6_35)
2. Visser A., Nardin L.G., Castro S. (2019) Integrating the Latest Artificial Intelligence Algorithms into the RoboCup Rescue Simulation Framework. In: Holz D., Genter K., Saad M., von Stryk O. (eds) RoboCup 2018: Robot World Cup XXII. RoboCup 2018. Lecture Notes in Computer Science, vol 11374. Springer, Cham. [https://doi.org/10.1007/978-3-030-27544-0\\_39](https://doi.org/10.1007/978-3-030-27544-0_39).
3. Akiyama H., Nakashima T. (2014) HELIOS Base: An Open Source Package for the RoboCup Soccer 2D Simulation. In: Behnke S., Veloso M., Visser A., Xiong R. (eds) RoboCup 2013: Robot World Cup XVII. RoboCup 2013. Lecture Notes in Computer Science, vol 8371. Springer, Berlin, Heidelberg. [https://doi.org/10.1007/978-3-662-44468-9\\_46](https://doi.org/10.1007/978-3-662-44468-9_46).
4. Fukushima T., Nakashima T., Akiyama H. Evaluation-function modeling with neural networks for RoboCup soccer //Electronics and Communications in Japan. – 2019. – Т. 102. – №. 12. – С. 40-46.
5. Кулинич А. А. Модель командного поведения агентов (роботов): когнитивный подход //Управление большими системами: сборник трудов. – 2014. – №. 51.
6. Fukushima T., Nakashima T., Akiyama H. Online opponent formation identification based on position information //Robot World Cup. – Springer, Cham, 2017. – С. 241-251.
7. Riley, P., Veloso, M.: Recognizing Probabilistic Opponent Movement Models. In: Birk, A., Coradeschi, S., Tadokoro, S. (eds.) RoboCup 2001. LNCS (LNAI), vol. 2377, pp. 453–458. Springer, Heidelberg (2002)

8. Pourmehri S., Dadkhah C. An overview on opponent modeling in RoboCup soccer simulation 2D //Robot Soccer World Cup. – Springer, Berlin, Heidelberg, 2011. – С. 402-414.
9. Akiyama H. et al. Learning Evaluation Function for RoboCup Soccer Simulation using Humans' Choice //2018 Joint 10th International Conference on Soft Computing and Intelligent Systems (SCIS) and 19th International Symposium on Advanced Intelligent Systems (ISIS). – IEEE, 2018. – С. 1416-1420
10. Ayanegui-Santiago, H.: Recognizing Team Formations in Multi-agent Systems: Applications in Robotic Soccer. In: Computational Collective Intelligence. Semantic Web, Social Networks and Multiagent Systems, pp. 163–173 (2009)
11. Пантелеев М. Г., Салимов А. Ф. Анализ алгоритмов навигации интеллектуального агента в виртуальном футболе. //Известия СПбГЭТУ ЛЭТИ. – 2020. – Т. 1 – С. 60-70.
12. Дубровин Ф. С., Щербатюк А. Ф. Исследование некоторых алгоритмов одноплатформенной мобильной навигации АНПА: результаты моделирования и морских испытаний. //Гироскопия и навигация. – 2015. – №. 4. – С. 160-172.
13. Кучерский Роман Владимирович, Манько Сергей Викторович Алгоритмы локальной навигации и картографии для бортовой системы управления автономного мобильного робота //Известия ЮФУ. Технические науки. – 2012. – Т. 3 – С. 13-22.
14. Cano P., Ruiz-del-Solar J. (2017) Robust Tracking of Multiple Soccer Robots Using Random Finite Sets. In: Behnke S., Sheh R., Sarmel S., Lee D. (eds) RoboCup 2016: Robot World Cup XX. RoboCup 2016. Lecture Notes in Computer Science, vol 9776. Springer, Cham.  
[https://doi.org/10.1007/978-3-319-68792-6\\_17](https://doi.org/10.1007/978-3-319-68792-6_17).

15. D.A. Petrunenko, S.A. Belyaev. Determining the Location of Players in Virtual Soccer // Software Journal: Theory and Applications. 2021. Vol. 2. Pp.1-14. DOI: 10.15827/2311-6749.21.2.1.
16. Беляев С.А. Интеллектуальные системы. программирование игроков в виртуальном футболе: Лабораторный практикум. //Спб.: Издательство СПбГЭТУ «ЛЭТИ» – 2020. – 62 с.
17. ФЕСТИНГЕР Л. Теория когнитивного диссонанса. – СПб.: Ювента, 1999. – С. 15–52.
18. [Электронный ресурс] // Обзор аналогов по НИР. URL: [https://github.com/DmitryPetr/predicting-coord-RoboCup/blob/new\\_rerfactor\\_code/predicting-coord-RoboCup/doc/petrunenko\\_nir\\_analog.pdf](https://github.com/DmitryPetr/predicting-coord-RoboCup/blob/new_rerfactor_code/predicting-coord-RoboCup/doc/petrunenko_nir_analog.pdf)
19. [Электронный ресурс] // Исходные данные: RoboCupSimData Files Overview. URL: <http://oliver.obst.eu/data/RoboCupSimData/overview.html> (дата обращения: 10.05.2021).
20. [Электронный ресурс] // Исходные коды программы. URL: <https://github.com/DmitryPetr/predicting-coord-RoboCup>